Rafael Simões do Carmo

Mapas de Características Quânticas Projetadas Baseados em Hamiltonianos Generalizados de Dois Qubits

Bauru

2026

Rafael Simões do Carmo

Mapas de Características Quânticas Projetadas Baseados em Hamiltonianos Generalizados de Dois Qubits

Trabalho de Estudos Especiais II apresentado ao Programa de Pós-Graduação em Ciência da Computação da Universidade Estadual Paulista "Júlio de Mesquita Filho", como requisito parcial para conclusão da disciplina Estudos Especiais II do Doutorado.

Universidade Estadual Paulista "Júlio de Mesquita Filho"

Faculdade de Ciências, Campus de Bauru

Programa de Pós-Graduação em Ciência da Computação

Orientador: Prof. Dr. Felipe Fernandes Fanchini

Bauru

2026

Rafael Simões do Carmo

Mapas de Características Quânticas Projetadas Baseados em Hamiltonianos Generalizados de Dois Qubits

Trabalho de Estudos Especiais II apresentado ao Programa de Pós-Graduação em Ciência da Computação da Universidade Estadual Paulista "Júlio de Mesquita Filho", como requisito parcial para conclusão da disciplina Estudos Especiais II do Doutorado.

Trabalho aprovado. Bauru, 2026.

Prof. Dr. Nome do Professor Responsável
Professor responsável pela disciplina Estudos Especiais II

Banca Examinadora:

Prof. Dr. Felipe Fernandes Fanchini
(Orientador)
Universidade Estadual Paulista "Júlio de Mesquita Filho"

Prof. Dr. Nome do Membro da Banca
Universidade Estadual Paulista "Júlio de Mesquita Filho"

Prof. Dr. Nome do Membro da Banca
Universidade Estadual Paulista "Júlio de Mesquita Filho"

Bauru
2026

Resumo

Mapas de características quânticas projetadas, em inglês *Projected Quantum Feature Maps* (PQFMs), constituem uma estratégia híbrida na qual circuitos quânticos baseados em Hamiltonianos são utilizados como geradores de atributos para modelos clássicos de aprendizado de máquina, buscando aumentar a performance dos mesmos. Neste trabalho, baseando-se nos recentes trabalhos desenvolvidos por empresas como Kipu Quantum e HSBC, desenvolvemos uma formulação unificada que constitui em uma família de PQFMs baseada em Hamiltonianos generalizados de dois qubits. A principal novidade está na codificação de atributos por eixos, além da já conhecida codificação por camadas, em que diferentes variáveis podem ser associadas a diferentes eixos de Pauli de um mesmo qubit, aumentando a densidade de informação de circuitos rasos e preservando compatibilidade com restrições de hardware. Os métodos foram implementados na biblioteca `pqfmlib` e avaliados em quatro bases biomédicas públicas de classificação binária, com experimentos em processadores quânticos IBM de até 156 qubits e simulações por vetor de estado. A avaliação utilizou validação cruzada aninhada, intervalos de confiança de 95% para diferenças de métricas e testes de Wilcoxon unilateral. Os resultados indicam que PQFMs podem produzir ganhos em modelos de aprendizado supervisionado, especialmente em cenários com bases de alta dimensionalidade, sendo a família Hamiltoniana generalizada foi a que apresentou o padrão mais consistente de ganhos estatisticamente consistentes, sugerindo um caminho promissor para a busca de utilidade quântica.

Palavras-chave: computação quântica; aprendizado de máquina quântico; mapas de características quânticas projetadas; Hamiltonianos de dois qubits; utilidade quântica; aprendizado supervisionado.

Abstract

Projected Quantum Feature Maps (PQFMs) constitute a hybrid strategy in which Hamiltonian-based quantum circuits are used as feature generators for classical machine-learning models, with the goal of improving their predictive performance. In this work, building on recent developments by companies such as Kipu Quantum and HSBC, we propose a unified formulation that defines a family of PQFMs based on generalized two-qubit Hamiltonians. The main novelty lies in axis-resolved feature encoding, in addition to the already established layer-wise encoding strategy, where different classical variables can be associated with different Pauli axes of the same qubit. This increases the information density of shallow circuits while preserving compatibility with hardware constraints. The proposed methods were implemented in the `pqfmlib` library and evaluated on four public biomedical binary-classification datasets, using experiments on IBM quantum processors with up to 156 qubits and statevector simulations. The evaluation employed nested cross-validation, 95% confidence intervals for paired metric differences, and one-sided Wilcoxon signed-rank tests. The results indicate that PQFMs can produce gains in supervised-learning models, especially in high-dimensional datasets, with the generalized Hamiltonian family showing the most consistent pattern of statistically supported gains, suggesting a promising path toward the search for quantum utility.

Keywords: quantum computing; quantum machine learning; projected quantum feature maps; two-qubit Hamiltonians; quantum utility; supervised learning.

Sumário

1 INTRODUÇÃO 7

2 MAPAS DE CARACTERÍSTICAS QUÂNTICAS PROJETADAS . . 10
2.1 Mapas de características quânticas projetadas 10
2.2 Mapa CD-Ising-glass 12
2.2.1 Atribuição de atributos ao hardware 14
2.3 Mapa de Heisenberg 14
2.4 Família Hamiltoniana generalizada de dois qubits 16
2.4.1 Codificação multi-eixo e modo de atributo compartilhado 17

3 METODOLOGIA EXPERIMENTAL 19
3.1 Bases de dados 19
3.2 Geração de características quânticas 19
3.3 Execução em hardware quântico 20
3.4 Simulações por vetor de estado 20
3.5 Pipeline clássica de aprendizado 21
3.6 Validação cruzada aninhada 21
3.7 Análise estatística pareada 22

4 RESULTADOS E DISCUSSÃO 24
4.1 Molecular Toxicity em hardware quântico 24
4.2 Controle de ordenação das amostras e desvio de calibração de hardware 26
4.3 Breast Cancer Radiology em alta dimensão 27
4.4 Simulações com espaços híbridos clássico-quânticos 28
4.5 Síntese comparativa 29

5 CONCLUSÃO 31

REFERÊNCIAS 33

APÊNDICES 35

APÊNDICE A – RESUMO ESTATÍSTICO COMPLEMENTAR . . 36
A.1 Resultados completos para a base Molecular Toxicity 36
A.2 Análise estatística pareada 38
A.2.1 ISPY1 38

A.2.2 Breast Cancer Pathology 39
A.2.3 Cardiac Disease 39

1 Introdução

A computação quântica tem sido apresentada como uma abordagem promissora para o tratamento de problemas computacionais difíceis ou pouco eficientes para computadores clássicos. Seja por resultados teóricos altamente reconhecidos e aclamados como os algoritmos de Shor e Grover (SHOR, 1997; GROVER, 1996), ou por resultados experimentais mais recentes em tarefas de amostragem randômica (*random sampling*) (BOIXO et al., 2018; ARUTE et al., 2019), muita expectativa tem sido criada sobre as possibilidades que esse novo paradigma de computação traz. Entretanto, a transição entre uma promessa geral de vantagem quântica e uma aplicação prática factível, para além de modelos brinquedo e problemas cuidadosamente engenheirados ainda é uma questão em aberto. O desafio se torna ainda mais evidente na era NISQ (*Noisy Intermediate Scale Quantum*), caracterizada por dispositivos intermediários e ruidosos, nos quais o número de qubits, o tempo de coerência e a fidelidade das portas impõem restrições severas à profundidade e à repetibilidade dos circuitos (PRESKILL, 2018; BHARTI et al., 2022).

No contexto de aprendizado de máquina, uma das principais motivações para o uso de computadores quânticos está na possibilidade de construir representações de dados que sejam difíceis de reproduzir por modelos clássicos e que, ao mesmo tempo, sejam úteis para tarefas preditivas. Essa motivação aparece em diferentes propostas de aprendizado de máquina quântico, incluindo classificadores variacionais, métodos baseados em kernels quânticos e estratégias híbridas de extração de características (REBENTROST; MOHSENI; LLOYD, 2014; FARHI; NEVEN, 2018; SCHULD; KILLORAN, 2019; HAVLÍČEK et al., 2019; HUANG et al., 2021a). Contudo, para aplicações reais não basta que uma transformação seja matematicamente sofisticada ou possivelmente difícil de simular. É necessário que ela produza atributos que melhorem, de forma robusta e estatisticamente sustentada, o desempenho de modelos de aprendizado supervisionado.

É nesse cenário que se inserem os *Projected Quantum Feature Maps* (PQFMs) (CICERI et al., 2025; FERENCZI et al., 2025; SIMEN et al., 2025b; SIMEN et al., 2025a; CARMO; JUNIOR; FANCHINI, 2026), aqui traduzidos como mapas de características quânticas projetadas. Inspirados nos chamados kernels quânticos projetados (HUANG et al., 2021b), a ideia central de um PQFM é simples do ponto de vista de uma pipeline de ciência de dados: um vetor clássico de entrada é codificado em um estado quântico por meio de um circuito dependente dos dados; em seguida, um conjunto finito de observáveis é medido; por fim, os valores esperados desses observáveis são armazenados como novas características clássicas. O processador quântico, portanto, não substitui o algoritmo de aprendizado de máquina clássico. Ele atua como uma etapa intermediária de engenharia de atributos.

Essa escolha tem uma consequência prática importante. Diferentemente de abordagens variacionais em aprendizado de máquina quântica, nas quais o treinamento usualmente envolve um ciclo iterativo de otimização de circuitos parametrizados, com sucessivas avaliações em simuladores ou computadores quânticos e potenciais dificuldades de treinabilidade associadas a fenômenos como *barren plateaus* (MCCLEAN et al., 2018), os PQFMs permitem que as características extraídas sejam calculadas uma vez, armazenadas e posteriormente reutilizadas por classificadores clássicos. Desse modo, o custo quântico fica concentrado apenas na geração da representação, enquanto todo restante pode ser realizados no ambiente clássico, possibilitando o melhor aproveitamento dos dois mundos. Essa separação é especialmente relevante nos tempos atuais considerando que o acesso a processadores quânticos reais é limitado e o tempo de execução em hardware é um recurso caro.

Dentro desse contexto, nosso objetivo não é apenas estudar modelos de PQFM já existentes, mas também propor uma generalização capaz de unificar e ampliar essas construções. Partindo de trabalhos anteriores baseados em mapas de Heisenberg unidimensionais (*Heisenberg maps*) (CICERI et al., 2025; FERENCZI et al., 2025) e, especialmente, na dinâmica quântica de modelos de Ising com termos contradiabáticos (*CD-Ising-glass*) (SIMEN et al., 2025a), formulamos neste trabalho uma família generalizada de PQFMs baseada em Hamiltonianos de dois qubits. Nessa formulação, de maneira análoga ao CD-Ising-glass, os atributos de uma base de dados são codificados nos coeficientes dos campos locais de Pauli, enquanto as dependências estatísticas entre pares de atributos, estimadas por informação mútua, são incorporadas aos termos 2-locais do Hamiltoniano. Assim, em vez de restringir a construção a uma única estrutura de interação, a proposta permite explorar diferentes combinações de campos locais e interações de dois corpos, dando origem a uma família de PQFMs com diferentes capacidades representacionais. O principal elemento dessa generalização é a codificação resolvida por eixos, na qual atributos distintos podem ser associados aos eixos X, Y e Z de um mesmo qubit, em vez de se restringirem a uma única direção de Pauli, permitindo codificar até 3 atributos por qubit físico. Complementarmente, a formulação também admite codificação multicamadas, isto é, a distribuição de blocos sucessivos de atributos ao longo de camadas adicionais do circuito, como explorado no contexto dos *Heisenberg maps* em (FERENCZI et al., 2025). Essa possibilidade aumenta ainda mais a capacidade de representação quando o número de atributos excede o número de qubits disponíveis, ainda que ao custo de maior profundidade de circuito, o que é particularmente relevante para bases reais de alta dimensionalidade.

Para garantir a reprodutibilidade dos experimentos e facilitar a disseminação dessas abordagens, tanto os PQFMs propostos neste trabalho quanto os modelos utilizados como referência foram implementados em Python em uma biblioteca pública, denominada `pqfmlib` (CARMO, 2026). A biblioteca permite construir, executar e avaliar mapas de características quânticas projetadas em processadores quânticos reais da IBM, bem como

em simuladores baseados no pacote Qiskit.

Como aplicação em problemas reais, realizamos um *benchmarking* em quatro bases médicas e biomédicas públicas voltadas a tarefas de classificação binária, utilizando um protocolo de validação cruzada aninhada. Para cada base, comparamos o desempenho de modelos treinados com atributos gerados pela nossa família de PQFMs com aqueles obtidos a partir dos PQFMs: CD-Ising-glass e Heisenberg map. Em duas bases de maior dimensionalidade, os experimentos foram executados em unidades reais de processamento quântico da IBM, ou *Quantum Processing Units* (QPUs), com até 156 qubits, incluindo os processadores `ibm_marrakesh`, `ibm_fez` e `ibm_kingston`, sendo este último utilizado com maior frequência por apresentar os melhores resultados entre os hardwares avaliados. Nas outras duas bases, por apresentarem menor número de atributos, os experimentos foram conduzidos por simulação exata via vetor de estado.

Em todos os casos, utilizamos o mesmo algoritmo clássico de aprendizado de máquina, o `Gradient Boosting`, treinado sob diferentes representações dos dados: atributos puramente clássicos, atributos puramente quânticos e, quando aplicável, combinações de atributos clássicos e quânticos. O protocolo experimental considerou 5 partições e 10 repetições, totalizando 50 avaliações externas. As diferenças de desempenho foram inicialmente analisadas a partir das médias obtidas para cada configuração e para cada métrica, com atenção especial à AUC. Para fornecer maior robustez estatística aos resultados, também realizamos uma análise pareada ao longo dos 50 experimentos, considerando as diferenças entre os resultados clássicos e quânticos, intervalos de confiança de 95% e o teste unilateral de Wilcoxon. De modo geral, os resultados evidenciam que a utilidade dos atributos quânticos projetados depende de diversos fatores, incluindo a base de dados, o mapa de características utilizado, o hardware quântico, os observáveis medidos e a estratégia de pós-processamento. Entretanto, nossa análise mostra que os PQFMs, com destaque para os advindos da nossa abordagem de Hamiltonianos generalizados de dois qubits, podem fornecer ganhos preditivos consistentes e estatisticamente robustos em alguns cenários, podendo ser um caminho viável para aplicações quânticas úteis ainda na era NISQ.

Esta dissertação está organizada da seguinte forma. O Capítulo 2 apresenta a fundamentação teórica, discutindo formalmente o que é um PQFM e introduzindo os 2 principais PQFMs da literatura e nossa família de PQFMs de Hamiltonianos de 2 qubits. O Capítulo 3 detalha a metodologia experimental, as bases de dados, os ambientes de hardware e simulação, a pipeline clássica e o protocolo estatístico. O Capítulo 5 apresenta e discute os resultados. Por fim, o Capítulo 6 sintetiza as conclusões, limitações e perspectivas futuras.

2 Mapas de Características Quânticas Projetadas

2.1 Mapas de características quânticas projetadas

PQFMs constituem uma estratégia híbrida de aprendizado de máquina quântico na qual um circuito quântico é utilizado como etapa intermediária de transformação de dados. Nessa abordagem, uma amostra clássica é codificada em um estado quântico por meio de uma transformação unitária e, em seguida, um conjunto fixo de observáveis é medido para produzir um novo vetor clássico de atributos. Assim, diferentemente de classificadores quânticos completos, a saída de um PQFM não é diretamente uma classe ou probabilidade de classe, mas uma representação clássica enriquecida que pode ser utilizada por algoritmos convencionais de aprendizado supervisionado.

Formalmente, seja $\mathcal{X} \subset \mathbb{R}^p$ o espaço original de atributos e seja $\mathcal{H}_Q = (\mathbb{C}^2)^{\otimes n}$ o espaço de Hilbert de n qubits. Um PQFM pode ser definido como a composição

$$\phi := \phi_M \circ \phi_U : \mathcal{X} \xrightarrow{\phi_U} \mathcal{H}_Q \xrightarrow{\phi_M} \mathcal{X}', \tag{2.1}$$

em que ϕ_U é o mapa de codificação quântica e ϕ_M é o mapa de projeção por medida. O mapa de codificação é realizado através de um operador unitário dependente dos dados, $\hat{U}_x$, que transforma um estado inicial fixo $|\psi_0\rangle$ em um estado parametrizado pela entrada:

$$|\psi_x\rangle = \phi_U(x) = \hat{U}_x|\psi_0\rangle. \tag{2.2}$$

Em seguida, define-se um conjunto de q observáveis Hermitianos $\{\hat{O}_j\}_{j=1}^q$. Cada atributo projetado é dado pelo valor esperado de um observável:

$$x'_j = \langle \hat{O}_j \rangle_{\psi_x} = \langle \psi_x | \hat{O}_j | \psi_x \rangle, \quad j = 1, \ldots, q. \tag{2.3}$$

Dessa forma, tanto a entrada quanto a saída de um PQFM são objetos clássicos. A parte quântica atua apenas como uma etapa de transformação no meio da *pipeline*, mais precisamente como um pré-processamento dos dados, uma engenharia de atributos. Depois de extraídos, esses atributos quânticos podem ser armazenados e posteriormente utilizados de diferentes formas: isoladamente, concatenados com os atributos originais ou submetidos a etapas clássicas de seleção e compressão. Essa característica torna os PQFMs particularmente atraentes no contexto de dispositivos quânticos ruidosos de curto

prazo, pois a etapa quântica pode ser executada uma vez para gerar uma representação que será reutilizada por classificadores clássicos.

A motivação dessa abordagem está intimamente relacionada à discussão sobre kernels quânticos e, em particular, aos *projected quantum kernels*. Em métodos de kernel quântico baseados em fidelidade, cada amostra é codificada em um estado quântico $|\psi_x\rangle$, e a similaridade entre duas amostras é calculada como

$$K_{ij}^{Q} = \kappa^{Q}(x_i, x_j) = \left|\langle\psi_{x_i}|\psi_{x_j}\rangle\right|^2 . \tag{2.4}$$

Essa abordagem é conceitualmente elegante, mas apresenta limitações práticas. Para N amostras, a construção completa da matriz de kernel envolve comparações entre pares, levando a um custo que cresce como $O(N^2)$ para um protocolo fixo. Além disso, quando os estados codificados ocupam uma região efetivamente muito alta dimensional do espaço de Hilbert, estados associados a amostras distintas podem se tornar quase ortogonais,

$$\left|\langle\psi_{x_i}|\psi_{x_j}\rangle\right|^2 \approx 0, \quad i \neq j, \tag{2.5}$$

de modo que a matriz de kernel se aproxima da identidade,

$$K^{Q} \approx I_N. \tag{2.6}$$

Nesse regime, o kernel passa a carregar pouca informação sobre relações de similaridade entre diferentes entradas. Esse fenômeno então motivou a proposta de *projected quantum kernels*, nos quais os estados quânticos são mapeados de volta a uma representação clássica aproximada por meio de medições de observáveis fisicamente motivados (HUANG et al., 2021a). Os PQFMs adotam essa mesma intuição de projeção, mas utilizam os valores medidos diretamente como atributos explícitos para modelos clássicos de aprendizado de máquina. Assim, em vez de depender apenas de uma matriz de similaridade construída a partir de fidelidades, a abordagem passa a explorar representações clássicas geradas por circuitos quânticos, abrindo espaço para diferentes escolhas de Hamiltonianos, observáveis e estratégias de codificação.

Sendo uma abordagem heurística, várias formulações de Hamiltonianos podem ser exploradas. Nas seções seguintes, veremos algumas das principais delas que serão consideradas neste trabalho. Primeiro, apresentaremos o PQFM CD-Ising-glass, inspirado no trabalho (SIMEN et al., 2025a) da empresa Kipu Quantum. Em seguida, discutiremos o mapa de Heisenberg unidimensional que foi a estratégia usada em(CICERI et al., 2025) pelo HSBC em conjunto com a IBM. Por fim, introduziremos nossa principal contribuição: a família generalizada baseada em Hamiltonianos de dois qubits.

2.2 Mapa CD-Ising-glass

O mapa CD-Ising-glass tem origem em propostas de extração de características quânticas inspiradas na dinâmica de evoluções quânticas rápidas, usando o chamado regime de *fast-annealing* dos computadores quânticos da D-Wave (D-Wave Quantum Inc., 2024), para Hamiltonianos do tipo Ising (SIMEN et al., 2025b). A ideia consiste em associar uma amostra clássica a esse hamiltoniano, no qual atributos individuais são codificados como campos locais e dependências estatísticas entre atributos são codificadas como acoplamentos. Em seguida, o sistema é evoluído por uma dinâmica rápida e não adiabática, e características quânticas são extraídas por medidas de observáveis locais e correlacionados.

No caso mais geral considerado na literatura, o Hamiltoniano dependente dos dados pode ser escrito como

$$H(x) = \sum_{i=1}^{n} x_i \sigma_i^z - \sum_{k=2}^{K} \sum_{S \in \mathcal{G}^{(k)}} c_S \prod_{i \in S} \sigma_i^z, \tag{2.7}$$

em que x_i representa a componente i do vetor de entrada, σ_i^z é o operador de Pauli Z atuando no qubit i, e c_S representa o peso de interação associado ao subconjunto S. Quando S contém m variáveis, esse peso pode ser definido como a informação mútua média entre os pares contidos no subconjunto:

$$c_S = \frac{1}{\binom{m}{2}} \sum_{\{a,b\} \subset S} I(x_a, x_b), \tag{2.8}$$

em que $I(x_a, x_b)$ denota a informação mútua pareada entre as variáveis x_a e x_b.

Na implementação usada neste trabalho, restringimos a construção a termos de dois corpos. Considera-se um Hamiltoniano adiabático interpolante

$$H_{ad}(t) = [1 - \lambda(t)]H_I + \lambda(t)H_F, \tag{2.9}$$

com Hamiltoniano inicial transversal

$$H_I = -\sum_{i=1}^{n} \sigma_i^x \tag{2.10}$$

e Hamiltoniano final de Ising

$$H_F(x) = \sum_{i=1}^{n} h_i \sigma_i^z + \sum_{(i,j) \in \mathcal{G}^{(k,e)}} J_{ij} \sigma_i^z \sigma_j^z. \tag{2.11}$$

Aqui, h_i é o valor normalizado do atributo associado ao qubit i, dado por $h_i = (x_i - \mu_i)/\sigma_i$, calculado a partir da média μ_i e do desvio padrão σ_i estimados no conjunto de treinamento. O termo J_{ij} quantifica a dependência estatística entre os atributos i e j, estimada por informação mútua. O conjunto $\mathcal{G}^{(k,e)}$, por sua vez, representa as interações compatíveis com a topologia do processador quântico escolhido.

A função de *schedule* adotada é a mesma comumente usada em trabalhos envolvendo termos contradiabáticos (CLAEYS et al., 2019; HUERTA-RUIZ et al., 2025)

$$\lambda(t) = \sin^2\left(\frac{\pi}{2}\sin^2\left(\frac{\pi t}{2T}\right)\right), \tag{2.12}$$

que satisfaz $\lambda(0) = 0$ e $\lambda(T) = 1$. A partir da aproximação de primeiro grau do potencial de calibre adiabático por comutadores aninhados (técnica introduzida em (CLAEYS et al., 2019)), obtém-se o termo contradiabático

$$A_\lambda^{(1)} = -2\alpha_1 \left[\sum_i h_i Y_i + \sum_{i<j} J_{ij}(Y_i Z_j + Z_i Y_j)\right]. \tag{2.13}$$

Esse termo é o Hamiltoniano efetivamente implementado como mapa de características no regime impulsivo em razão de ser bastante dominante nesse regime em relação aos termos adiabáticos. A unidade do mapa pode ser aproximada por um produto de Trotter de blocos locais e de dois qubits:

$$U_{CD}(x) \simeq \prod_{s=1}^{N_{steps}} \left[\prod_i U_Y^{(i)}(\theta_i^{(s)}) \prod_{(i,j)\in E} U_{YZ+ZY}^{(i,j)}(\theta_{ij}^{(s)})\right]. \tag{2.14}$$

Nos experimentos principais, segue-se a configuração de um único passo de Trotter, isto é, $N_{steps} = 1$, coerente com a interpretação do regime impulsivo. A biblioteca `pqfmlib`, entretanto, permite o uso de mais passos quando desejado. Além disso, nosso trabalho também permite a codificação de mais atributos por qubit a partir do uso de mais blocos unitários de codificação como o da Eq. 2.14. Isso está ilustrado na Fig. 2.1.

No que diz respeito a extração dos atributos, isso é feito utilizando valores esperados de um qubit e dois qubits considerando observáveis apenas do eixo Z,

$$x'_i = \langle\psi_f|\sigma_i^z|\psi_f\rangle, \qquad x'_{ij} = \langle\psi_f|\sigma_i^z\sigma_j^z|\psi_f\rangle, \tag{2.15}$$

onde $i, j = 1, \ldots, n$, e n denota o número de qubits usados para a codificação. Observáveis com maior ordem de correlação podem ser utilizados, como mostra o trabalho original, porém aqui focamos apenas em atributos advindos de observáveis 1-local e 2-local.

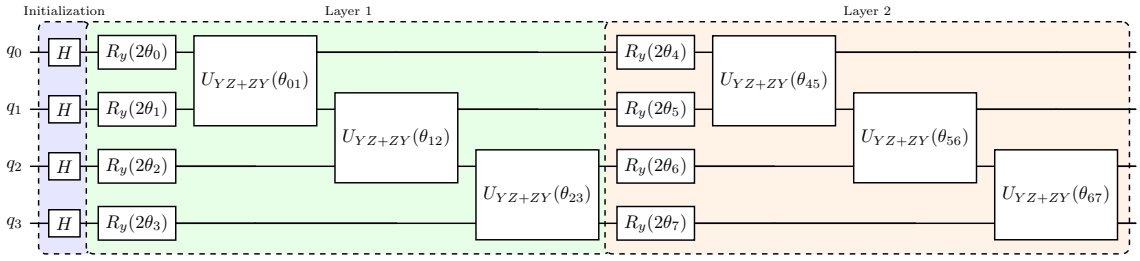


Figura 2.1 – Representação esquemática do mapa CD-Ising-glass com oito atributos codificados em um registrador de quatro qubits por meio de duas camadas. As rotações locais codificam os atributos, enquanto os blocos U_{YZ+ZY} codificam correlações clássicas entre dois atributos estimada por informação mútua.

2.2.1 Atribuição de atributos ao hardware

A conectividade de processadores quânticos reais limita quais interações de dois qubits podem ser implementadas de forma direta. Por isso, a atribuição de variáveis clássicas a qubits físicos não é arbitrária. O objetivo é posicionar atributos estatisticamente dependentes em qubits vizinhos, preferencialmente em arestas do hardware que contenham baixo erro de portas de 2 qubits.

Dada uma matriz de informação mútua J calculada a partir dos atributos e um conjunto de arestas físicas E, define-se uma permutação π que associa atributos a qubits. A função de aptidão utilizada na atribuição pode ser escrita como

$$F(\pi) = \sum_{(i,j)\in E} w_{ij} J_{\pi(i),\pi(j)}, \tag{2.16}$$

em que w_{ij} pode ser igual a 1 ou incorporar informações de calibração, como taxas de erro de portas de dois qubits. Na prática, a biblioteca segue a mesma linha do trabalho original (SIMEN et al., 2025a) utilizando uma busca heurística por algoritmo genético, com seleção por torneio, cruzamento por ordem, mutação e elitismo. Essa etapa é essencial para aproximar a estrutura estatística dos dados da estrutura física do processador. O diferencial é que aqui estendemos essa abordagem para incluir o caso de codificar mais de um atributo por qubit. Isso é feito mantendo atributos com alta informação mútua dentro de um mesmo bloco, de forma que eles sejam mapeados em qubits vizinhos (veja Fig. 2.1).

2.3 Mapa de Heisenberg

O mapa de Heisenberg foi uma das primeiras abordagens a adotar explicitamente a terminologia de PQFM. Ele é motivado por dinâmicas de cadeias de spin unidimensionais, tendo sido o mapa Hamiltoniano adotado na introdução dos kernels quânticos projetados,

da qual os PQFMs são inspirados (HUANG et al., 2021b). Esse Hamiltoniano pode ser escrito como

$$H_J = \frac{1}{4}\sum_{j=1}^{n-1} J_j \left(X_j X_{j+1} + Y_j Y_{j+1} + Z_j Z_{j+1}\right), \tag{2.17}$$

em que J_j é o acoplamento associado à aresta $(j, j+1)$. Diferentemente do mapa CD-Ising-glass, aqui os dados são codificados nos termos de interação, e não em campos locais. Para evitar confusão com os pesos de informação mútua, denota-se o parâmetro de codificação de Heisenberg por η_j:

$$\eta_j = 2\pi \tanh\left(\frac{h_j}{3}\right). \tag{2.18}$$

Para uma aresta $(j, j+1)$ no bloco de atributos b, o bloco de interação é dado por

$$U_j^{(b)}(x) = \exp\left[-i\gamma\eta_j^{(b)}\left(X_j X_{j+1} + Y_j Y_{j+1} + Z_j Z_{j+1}\right)\right], \tag{2.19}$$

em que γ é um parâmetro de escala. Como cada bloco unidimensional com n qubits codifica $n-1$ atributos, vetores com $p > n-1$ atributos exigem empilhamento de blocos:

$$B = \left\lceil \frac{p}{n-1} \right\rceil. \tag{2.20}$$

As características quânticas são extraídas de valores esperados locais de Pauli,

$$x'_{a,j} = \langle\psi_x|\sigma_j^a|\psi_x\rangle, \quad a \in \{X, Y, Z\}, \tag{2.21}$$

e, opcionalmente, de observáveis de dois corpos de mesmo eixo,

$$x'_{aa,jk} = \langle\psi_x|\sigma_j^a\sigma_k^a|\psi_x\rangle, \quad a \in \{X, Y, Z\}. \tag{2.22}$$

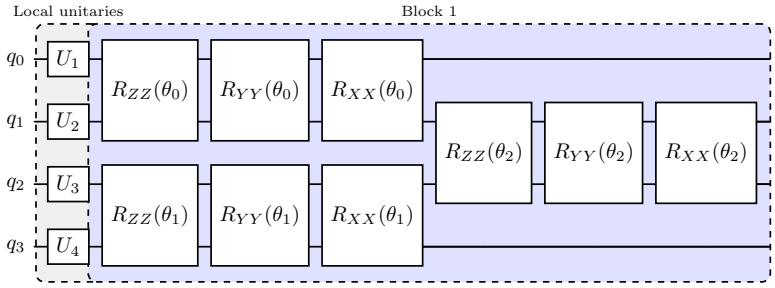


Figura 2.2 – Exemplo de bloco de codificação do PQFM de Heisenberg com quatro qubits. Após unidades locais aleatórias, blocos R_{ZZ}, R_{YY} e R_{XX} são aplicados em pares de qubits.

A estrutura unidimensional torna esse mapa mais favorável a simulações por estados de produto matricial. Essa característica pode ser uma vantagem computacional, mas também torna o modelo menos alinhado a regimes de difícil simulação clássica quando comparado a mapas que exploram uma fração maior da conectividade de um processador quântico real (LIU; ARUNACHALAM; TEMME, 2021; GLICK et al., 2024).

2.4 Família Hamiltoniana generalizada de dois qubits

A principal contribuição metodológica deste trabalho é a família generalizada de PQFMs Hamiltonianos de dois qubits, implementada na biblioteca `pqfmlib` como `XYZProjectiveQFM`. A construção parte da expansão geral de um Hamiltoniano de dois qubits na base de Pauli (KLASSEN; TERHAL, 2019):

$$H = \sum_{\mu,\nu\in\{I,X,Y,Z\}} a_{\mu\nu}\sigma^{\mu}\otimes\sigma^{\nu}, \quad a_{\mu\nu}\in\mathbb{R}. \tag{2.23}$$

Inspirada pela estrutura do CD-Ising-glass, a família proposta codifica atributos normalizados em campos locais e dependências pareadas em interações de dois corpos. Dessa forma, o Hamiltoniano geral que utilizamos é

$$H_{XYZ}(x) = \sum_{i=1}^{n}\sum_{a\in\mathcal{A}} h_i^{(a)}\sigma_i^a + \sum_{(i,j)\in E}\sum_{(a,b)\in\mathcal{P}} J_{ij}^{(ab)}\sigma_i^a\sigma_j^b. \tag{2.24}$$

Nessa expressão, $\mathcal{A}\subseteq\{x,y,z\}$ é o conjunto de eixos de Pauli ativos para codificação local, E é o grafo de interações de dois qubits e $\mathcal{P}\subseteq\mathcal{A}\times\mathcal{A}$ define os canais de Pauli usados nas interações. Dessa estrutura, extraímos três famílias principais:

$$\mathcal{P}_{diag} = \{(a, a) : a \in \mathcal{A}\}, \tag{2.25}$$

$$\mathcal{P}_{cross} = \{(a, b) : a, b \in \mathcal{A}, a \neq b\}, \tag{2.26}$$

$$\mathcal{P}_{full} = \mathcal{P}_{diag} \cup \mathcal{P}_{cross}. \tag{2.27}$$

Assim, são suportadas configurações diagonais, cruzadas e completas. Por exemplo, se $\mathcal{A} = \{x, y, z\}$ e $\mathcal{P} = \mathcal{P}_{diag}$, obtém-se o mapa diagonal XYZ:

$$H_{diag} = \sum_i \left(h_i^{(x)} X_i + h_i^{(y)} Y_i + h_i^{(z)} Z_i\right) + \sum_{(i,j)\in E} \left(J_{ij}^{(xx)} X_i X_j + J_{ij}^{(yy)} Y_i Y_j + J_{ij}^{(zz)} Z_i Z_j\right). \tag{2.28}$$

Se forem usados apenas canais cruzados, obtém-se um Hamiltoniano com termos como X_iY_j, Y_iX_j, X_iZ_j, Z_iX_j, Y_iZ_j e Z_iY_j. Por fim, a configuração completa inclui todos os canais de dois corpos entre os eixos ativos.

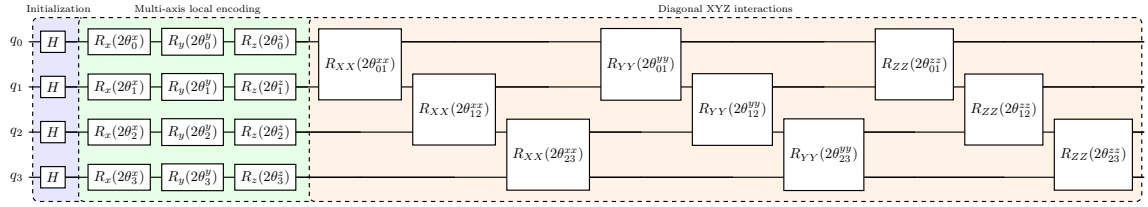


Figura 2.3 – Circuito esquemático de um PQFM diagonal XYZ com codificação multi-eixo. Cada qubit recebe rotações locais em X, Y e Z, permitindo codificar três atributos por qubit em uma única camada. Aqui a representação foi feita de maneira em cadeia, por primeiros vizinhos, apenas de maneira ilustrativa. Na prática, o padrão de interação dependerá do mapa de acoplaments da QPU.

2.4.1 Codificação multi-eixo e modo de atributo compartilhado

A codificação resolvida por eixos, chamada de `multi-axis` na `pqfmlib`, é a novidade central da família generalizada. Se um registrador possui n qubits e utiliza $|\mathcal{A}|$ eixos ativos, então uma camada pode codificar até $n|\mathcal{A}|$ atributos distintos. Com L camadas, a capacidade teórica de codificação multi-eixo é

$$C_{multi-axis} = n|\mathcal{A}|L. \tag{2.29}$$

Por exemplo, com $n = 4$ qubits, $\mathcal{A} = \{x, y, z\}$ e $L = 2$ camadas, pode-se codificar até $4 \times 3 \times 2 = 24$ atributos. Isso contrasta com estratégias em que apenas um atributo é associado a cada qubit por camada.

A atribuição de atributos também precisa ser generalizada. Em vez de associar atributos apenas a qubits, associa-se cada atributo a um par (i, a), em que i denota o

qubit e a denota o eixo de Pauli. Assim, a função de aptidão do algoritmo genético passa a ser

$$F(\pi) = \sum_{(i,j)\in E} \sum_{(a,b)\in\mathcal{P}} w_{ij} J_{\pi(i,a),\pi(j,b)}. \tag{2.30}$$

Essa formulação preserva a ideia de mapear pares de alta informação mútua em interações físicas disponíveis, mas amplia o espaço de busca para considerar também os eixos de codificação.

Além do modo multi-eixo, a biblioteca permite o modo de atributo compartilhado (`shared_feature`), como ilustrado no exemplo mencionado a pouco. Nesse caso, a mesma variável clássica é codificada ao longo de múltiplos eixos de Pauli de um mesmo qubit. A capacidade de atributos distintos passa a ser

$$C_{shared} = nL, \tag{2.31}$$

mas cada mesmo atributo é encodado em diferentes direções. Essa estratégia pode gerar representações complementares da mesma informação, ainda que não aumente o número de variáveis distintas por camada.

3 Metodologia experimental

3.1 Bases de dados

Foram utilizadas quatro bases públicas de classificação binária na área médica e biomédica. A escolha dessas bases buscou cobrir diferentes regimes de número de amostras, dimensionalidade e domínio de aplicação, mantendo compatibilidade com as restrições de execução em hardware quântico e simulação.

Tabela 3.1 – Resumo das bases de dados e regimes experimentais.

Base	**Amostras**	**Atributos originais**	**Atributos usados**	**Regime experimental**
Molecular Toxicity	171	1203	156	IBM QPU
Breast Cancer Radiology	161	370	370	IBM QPU
Breast Cancer Pathology	569	30	30	Simulação por vetor de estado seleção de atributos via SHAP
Cardiac Disease Cleveland	303	13	13	Simulação por vetor de estado redução dimensional via PCA

A base Molecular Toxicity foi usada como principal referência de comparação em hardware quântico, por se tratar de um dos datasets mais utilizados nos trabalhos originais da Kiu Quantum (SIMEN et al., 2025b; SIMEN et al., 2025a). A base Breast Cancer Radiology foi utilizada como um teste de maior dimensionalidade em hardware real, pois todos os seus 370 atributos foram mantidos. As bases Breast Cancer Pathology e Cardiac Disease foram avaliadas em simulação, permitindo explorar estratégias híbridas de seleção e compressão de atributos.

Em todos os experimentos, os atributos de entrada foram padronizados para média zero e variância unitária. Valores ausentes, quando presentes, foram imputados pela mediana calculada no conjunto de treinamento correspondente. Essa escolha evita que estatísticas do conjunto de teste sejam usadas durante o treinamento.

3.2 Geração de características quânticas

A geração de características quânticas foi realizada com a biblioteca `pqfmlib`. Foram avaliadas três famílias de mapas:

1. CD-Ising-glass, usado como referência inspirada em dinâmica contradiabática;
2. Heisenberg unidimensional, usado como referência Hamiltoniana baseada em cadeia;

3. família Hamiltoniana generalizada de dois qubits, incluindo variantes diagonais, cruzadas e completas.

Para cada configuração, a saída da etapa quântica é uma matriz clássica de atributos, formada por valores esperados medidos ou simulados. Dependendo do mapa, foram considerados observáveis locais, como $\langle X_i \rangle$, $\langle Y_i \rangle$ e $\langle Z_i \rangle$, e observáveis de dois corpos, como $\langle X_i X_j \rangle$, $\langle Y_i Y_j \rangle$ e $\langle Z_i Z_j \rangle$. No mapa CD-Ising-glass, o foco principal foi em observáveis associados ao eixo Z. No mapa de Heisenberg, características locais foram extraídas nos eixos X, Y e Z. Na família generalizada, os observáveis disponíveis dependem dos eixos ativos e dos canais de interação de cada configuração.

3.3 Execução em hardware quântico

Para a base Molecular Toxicity, foram comparados três processadores quânticos IBM: `ibm_marrakesh`, `ibm_fez` e `ibm_kingston`. Os experimentos consideraram regimes de aproximadamente 52, 78 e 156 qubits codificados, permitindo avaliar a influência do orçamento de qubits e da estratégia de multi-codificação. Todas as execuções em hardware utilizaram 4096 *shots*, sem correção de erro quântico e sem técnicas adicionais de mitigação de erro.

Para a base Breast Cancer Radiology, utilizou-se apenas o backend `ibm_kingston`. Essa escolha foi motivada pelo desempenho observado nos experimentos com Molecular Toxicity e pela necessidade de reduzir o consumo de recursos de QPU. Nesse experimento, todos os 370 atributos foram mantidos, e diferentes famílias de PQFMs foram configuradas para codificar a mesma base com diferentes números de qubits e observáveis.

3.4 Simulações por vetor de estado

As bases Breast Cancer Pathology e Cardiac Disease foram avaliadas com o modo de vetor de estado do *AerSimulator* do Qiskit. Apesar de serem simulações ideais, a atribuição de atributos aos qubits usou a mesma topologia do `ibm_kingston`. Essa decisão aproxima os experimentos simulados do regime de hardware, pois preserva a lógica de seleção de pares de alta informação mútua sob restrições de conectividade, além de gerar circuitos mais rasos.

Nas simulações, também foram avaliadas estratégias híbridas de seleção ou compressão de atributos. Para Breast Cancer Pathology, utilizou-se SHAP para selecionar os atributos quânticos mais relevantes e, separadamente, os melhores atributos dentro da união entre atributos clássicos e quânticos. Para Cardiac Disease, utilizou-se PCA sobre os atributos quânticos antes da concatenação com os atributos clássicos, preservando 13 componentes principais, de modo a manter o mesmo critério empírico de dimensionalidade.

3.5 Pipeline clássica de aprendizado

A pipeline clássica foi baseada em *Gradient Boosting*, com semente aleatória fixa em 42. A seleção de hiperparâmetros foi feita por `GridSearch`, usando AUC como métrica primária de seleção. O espaço de busca é apresentado na Tabela 3.2.

Tabela 3.2 – Espaço de busca de hiperparâmetros do classificador *Gradient Boosting*.

Hiperparâmetro	**Valores avaliados**
`n_estimators`	{80, 100, 120, 140, 160}
`max_depth`	{2, 5, 7, 9, 11}
`criterion`	{`friedman_mse`, `squared_error`}

Foram avaliadas três formas principais de representação:

1. atributos clássicos originais, utilizados como linha de base;
2. atributos quânticos extraídos pelo PQFM, usados isoladamente;
3. atributos híbridos clássico-quânticos, obtidos por concatenação ou seleção/compressão.

As métricas reportadas foram AUC, F1-score, precisão, recall e acurácia. A AUC foi tratada como métrica primária por ser menos dependente de um limiar específico de decisão, enquanto as demais métricas foram usadas para caracterizar o comportamento do classificador.

3.6 Validação cruzada aninhada

O protocolo de avaliação foi baseado em validação cruzada aninhada. O laço externo consistiu em validação cruzada estratificada com 5 partições e 10 repetições, resultando em 50 avaliações externas. Em cada partição externa, o conjunto de teste foi mantido completamente separado. A seleção de hiperparâmetros foi realizada apenas dentro do conjunto de treinamento, usando uma divisão interna estratificada 80/20 implementada com `PredefinedSplit` dentro do `GridSearchCV`.

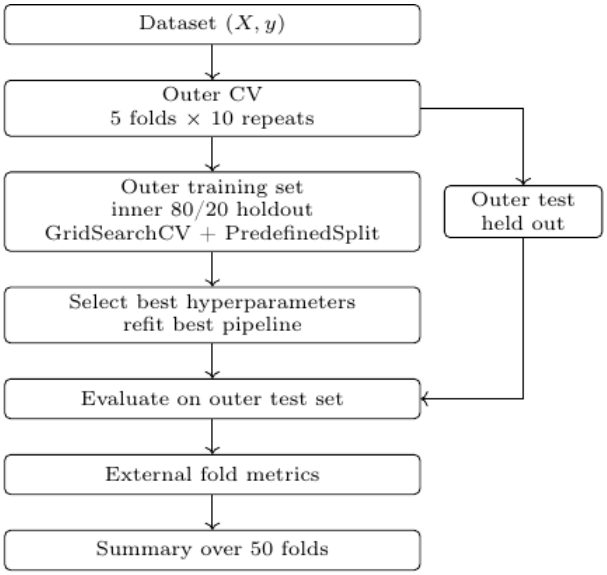


Figura 3.1 – Esquema da validação cruzada aninhada usada para seleção de modelos e estimação externa de desempenho.

Após a seleção dos melhores hiperparâmetros, a pipeline foi reajustada no conjunto de treinamento externo completo e avaliada uma única vez no conjunto de teste externo. Essa separação é essencial para evitar que o processo de seleção de modelo contamine a estimativa final de desempenho.

3.7 Análise estatística pareada

Para comparar cada configuração quântica ou híbrida com a linha de base clássica, foi calculada, para cada partição externa i, a diferença pareada

$$\Delta_i = M_i^{caso} - M_i^{classico}, \tag{3.1}$$

em que M_i^{caso} é a métrica obtida pela configuração avaliada e $M_i^{classico}$ é a métrica obtida pela linha de base clássica na mesma dobra. Essa comparação pareada reduz o efeito da variabilidade entre divisões treino-teste.

Para cada métrica, reportou-se a média das diferenças Δ_i, um intervalo de confiança de 95% para a média da diferença e o teste de Wilcoxon (WILCOXON, 1945) pareado unilateral com alternativa “greater”, isto é, testando se a configuração avaliada tende a superar a linha de base clássica. Os resultados foram interpretados segundo quatro rótulos:

- **Consistente**: média positiva, intervalo de confiança totalmente acima de zero e $p < 0,05$ no teste de Wilcoxon;

- **Promissor**: média positiva e $p < 0,05$, mas intervalo de confiança cruzando zero;
- **Sugestivo**: média positiva, intervalo cruzando zero e $0,05 \leq p < 0,10$;
- **Tendência positiva**: média positiva, mas sem evidência estatística suficiente nos critérios anteriores.

Essa nomenclatura evita tratar todo ganho médio como evidência robusta, distinguindo melhorias estatisticamente apoiadas de tendências exploratórias.

4 Resultados e discussão

4.1 Molecular Toxicity em hardware quântico

A base Molecular Toxicity foi usada como principal experimento em hardware real. O objetivo foi avaliar como diferentes famílias de PQFMs se comportam quando executadas em processadores IBM e quando o número de qubits codificados varia. Foram considerados regimes de aproximadamente 52, 78 e 156 qubits, correspondendo a 3, 2 e 1 atributo clássico por qubit, respectivamente.

Os resultados mostram que o benefício das características quânticas não é uniforme. Para o CD-Ising-glass, os ganhos são mais claros quando o número de qubits disponíveis aumenta. Nos regimes mais comprimidos, com 52 e 78 qubits, as melhorias dependem da métrica e do backend. No regime de 156 qubits, especialmente em `ibm_kingston`, observam-se melhorias mais consistentes, incluindo ganhos em AUC, precisão, revocação, acurácia e F1 quando observáveis de dois corpos são considerados.

O mapa de Heisenberg apresentou resultados mais modestos nesse benchmark. Embora algumas métricas tenham melhorado em configurações específicas, o padrão de ganhos foi menos consistente. Além disso, por exigir medições nos três eixos de Pauli, o mapa de Heisenberg demanda maior tempo de execução em QPU quando comparado a mapas de eixo único.

A família Hamiltoniana generalizada apresentou o padrão mais consistente de melhorias. Nas configurações comprimidas, a estratégia multi-eixo mostrou-se mais efetiva do que simplesmente aumentar o número de blocos de codificação. Isso sugere que distribuir a informação entre diferentes eixos de Pauli pode ser mais eficiente do que repetir camadas com um único atributo por qubit.

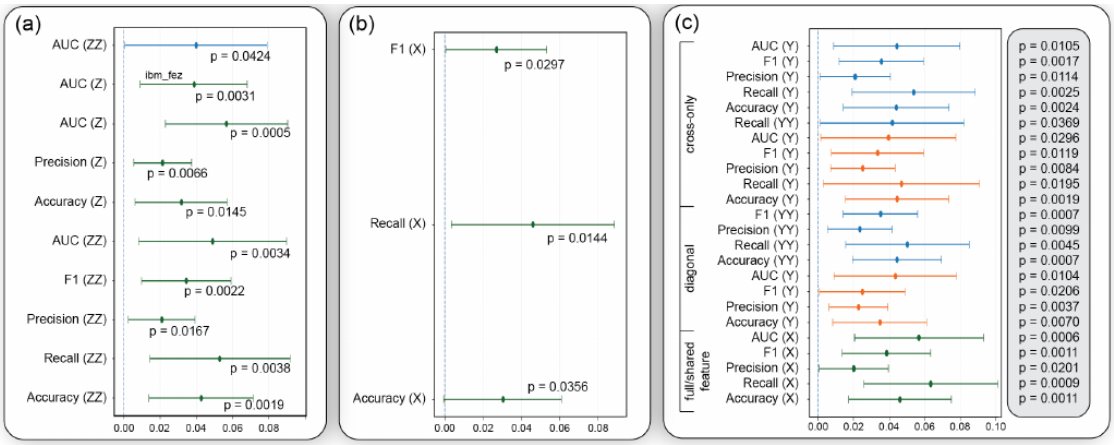


Figura 4.1 – Melhorias estatísticas pareadas em relação à base clássica para a base de dados *Toxicity*. O painel (a) mostra o PQFM CD-Ising-glass, o painel (b) o mapa de Heisenberg e o painel (c) a família de mapas XYZ introduzida neste trabalho. Os intervalos apresentados correspondem às diferenças médias pareadas e aos intervalos de confiança de 95%. As cores indicam o orçamento de qubits utilizado em cada configuração, com azul, laranja e verde correspondendo a 52, 78 e 156 qubits, respectivamente. Os rótulos entre parênteses indicam o observável medido utilizado para extrair as respectivas características quânticas. Salvo indicação em contrário, os resultados correspondem ao processador `ibm_kingston`; o painel (b) utiliza o processador `ibm_marrakesh`.

A Figura 4.1 resume os principais ganhos pareados. O painel referente às família XYZ do Hamiltoniano generalizado de 2 qubits mostra que todas elas superam a linha de base clássica em várias métricas e orçamentos de qubits. Esse resultado é importante porque indica que a generalização Hamiltoniana não apenas aumenta a flexibilidade formal do mapa, mas também se traduz em melhorias empíricas em um cenário de hardware quântico real.

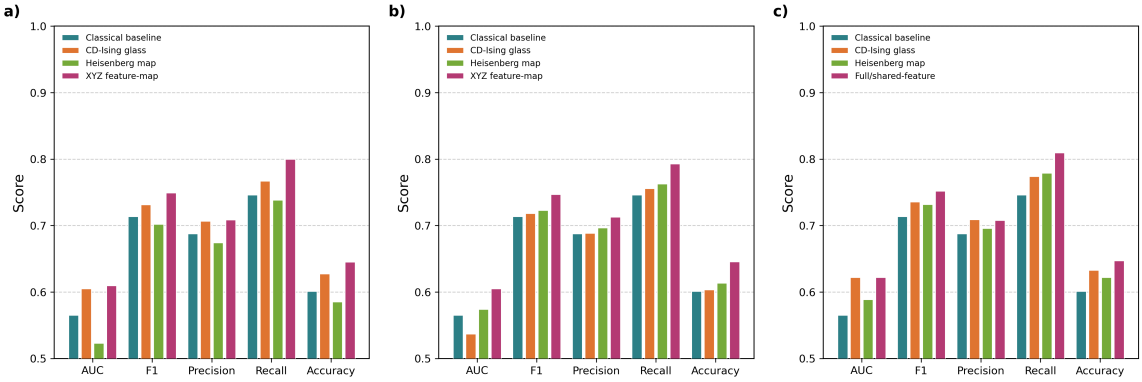


Figura 4.2 – Resumo de desempenho na base de dados *Toxicity* utilizando o protocolo de validação aninhada apresentado na Fig. 3.1. As barras indicam o desempenho médio para AUC, F1-score, precisão, revocação e acurácia; medianas e desvios-padrão não são mostrados. Os painéis (a), (b) e (c) correspondem aos regimes de codificação com aproximadamente 52, 78 e 156 qubits codificados, respectivamente. Para cada família de PQFM e número de qubits, a configuração exibida é aquela selecionada de acordo com a maior AUC média dos testes feitos; todas as demais métricas são obtidas da mesma configuração selecionada, sem combinação entre diferentes observáveis ou configurações. Os resultados do CD-Ising-glass e da família de PQFMs baseada em Hamiltonianos generalizados de dois qubits foram obtidos no processador `ibm_kingston`, enquanto os resultados do mapa de Heisenberg foram obtidos no processador `ibm_marrakesh`. Para a família de PQFMs baseada em Hamiltonianos generalizados de dois qubits, as variantes selecionadas são XYZ apenas com termos cruzados no painel (a), XY apenas com termos cruzados no painel (b) e XYZ completo com atributo compartilhado no painel (c).

A Figura 4.2 ilustra o desempenho comparativo entre os PQFMs considerados, avaliando-os pela média em cada métrica considerada. No regime de 156 qubits, a configuração completa com atributo compartilhado atinge os melhores valores agregados em F1 e revocação, mantendo AUC competitiva. Isso indica que reencodar o mesmo atributo em diferentes eixos pode gerar estrutura complementar útil, mesmo sem aumentar o número de variáveis distintas codificadas.

4.2 Controle de ordenação das amostras e desvio de calibração de hardware

Um ponto metodológico relevante é o controle da ordem de submissão das amostras ao hardware. Quando amostras são enviadas sequencialmente a uma QPU, as características extraídas podem ser afetadas por desvio de calibração e ruído, pois a QPU tende a descalibrar com o tempo. Se a base estiver ordenada por classe, esse desvio pode se alinhar artificialmente com os rótulos, gerando uma separação entre classes, devido ao fato de na

prática estarmos aplicando funções de transformação diferentes às amostras.

Por esse motivo, os resultados principais foram obtidos com amostras embaralhadas. Experimentos de controle com a base em ordem original produziram ganhos maiores, comparáveis aos reportados em trabalhos anteriores sobre a mesma base. A interpretação adotada é que parte desses ganhos pode refletir um efeito dependente da ordem de aquisição, e não apenas informação relevante codificada pelo PQFM. Assim, os resultados embaralhados são mais conservadores e mais fiéis ao papel desejado do mapa quântico como transformador de atributos dependente da entrada.

4.3 Breast Cancer Radiology em alta dimensão

O segundo experimento em hardware real usou a base Breast Cancer Radiology, com 370 atributos e 161 amostras. Diferentemente da base Molecular Toxicity, nesse caso todos os atributos disponíveis foram mantidos. O objetivo foi avaliar se as estratégias de codificação multi-eixo e multi-camada conseguem lidar com um espaço de entrada de dimensão maior que o número de qubits total do hardware quântico utilizado. Afinal, esse é o principal intuito de usarmos codificação de múltiplos atributos por qubit.

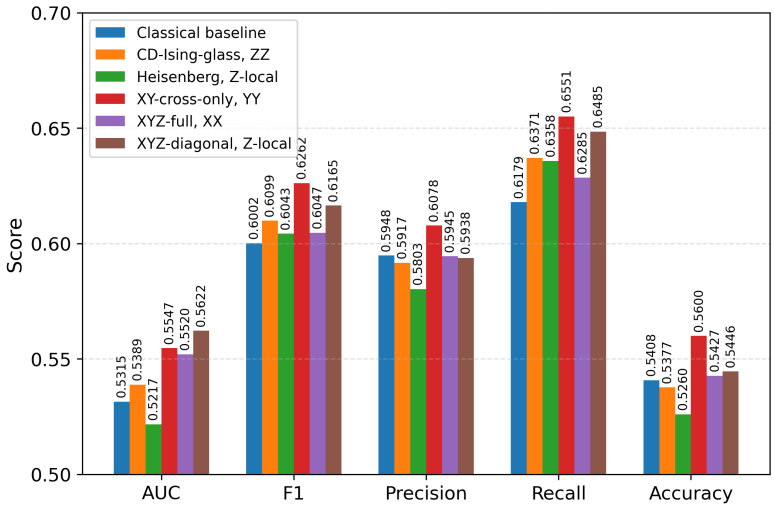


Figura 4.3 – Comparação de desempenho na base *ISPY1* no processador `ibm_kingston`, utilizando 370 atributos de entrada e 161 amostras sob o protocolo de validação aninhada da Fig. 3.1. As barras comparam a base clássica com a melhor configuração de atributos quânticos de cada família, selecionada pela AUC. Foram consideradas codificações CD-Ising-glass, Heisenberg e variantes multi-eixo da família Hamiltoniana generalizada. Todas as configurações codificam os mesmos 370 atributos, mas utilizam diferentes números de qubits e observáveis devido à estrutura de cada mapa. Entre elas, a variante XY apenas com termos cruzados é a única a combinar codificação multi-eixo e multicamadas.

Algoritmo	Qubits	Atributos	Clássico					SHAP Quântico					SHAP Clássico+Quântico					%Q
			AUC	F1	Prec.	Revoc.	Acur.	AUC	F1	Prec.	Revoc.	Acur.	AUC	F1	Prec.	Revoc.	Acur.	
CD-Ising-glass	20	30	0.9847	0.9643	0.9574	0.9717	0.9548	0.9825	0.9534	0.9522	0.9551	0.9415	**0.9880**	**0.9649**	**0.9596**	0.9708	**0.9557**	35.93
Heisenberg	20	30	0.9847	0.9643	0.9574	0.9717	0.9548	**0.9911**	**0.9684**	**0.9637**	**0.9737**	**0.9601**	0.9900	0.9672	0.9621	0.9728	0.9585	65.40
XYZ-full/shared-feature	20	30	0.9847	0.9643	0.9574	0.9717	0.9548	0.9596	0.9159	0.9055	0.9272	0.8933	**0.9885**	**0.9659**	**0.9581**	**0.9745**	**0.9567**	43.00
XYZ-diagonal/shared-feature	20	30	0.9847	0.9643	0.9574	0.9717	0.9548	0.9653	0.9299	0.9200	0.9409	0.9109	**0.9884**	**0.9648**	**0.9603**	0.9700	**0.9555**	47.47
XY-cross-only	15	30	0.9847	0.9643	0.9574	0.9717	0.9548	0.9584	0.9174	0.9019	0.9345	0.8944	**0.9896**	0.9637	0.9551	**0.9731**	0.9539	32.27

Tabela 4.1 – Resultados para a base *Breast Cancer* utilizando seleção de atributos baseada em SHAP com os 30 atributos mais relevantes e o protocolo de validação aninhada da Fig. 3.1. Comparam-se as variantes CD-Ising-glass, Heisenberg, XYZ-full/shared-feature, XYZ-diagonal/shared-feature e XY-cross-only. A base clássica utiliza os 30 atributos originais. O bloco "SHAP Quântico" apresenta os resultados obtidos com os 30 atributos quânticos mais relevantes, enquanto o bloco "SHAP Clássico+Quântico" mostra os resultados da seleção dos 30 atributos mais relevantes a partir da união entre atributos clássicos e quânticos. A última coluna indica a porcentagem média de atributos quânticos selecionados nesse conjunto misto. Todas as seleções por SHAP foram realizadas sem vazamento de informação dentro do protocolo aninhado. Entradas em negrito indicam, para cada linha e métrica, o melhor resultado quântico ou híbrido quando superior à base clássica.

Na Figura 4.3, observa-se que a família Hamiltoniana generalizada novamente supera os mapas de referência em algumas métricas, com destaque para a configuração diagonal XYZ, que obteve o melhor AUC agregado entre as configurações avaliadas. Em particular, a AUC aumentou de 0,5315 na linha de base clássica para 0,5622 na configuração diagonal, e a revocação aumentou de 0,6179 para 0,6485.

Entretanto, a análise pareada não identificou ganhos consistentemente significativos nesse experimento. Alguns resultados foram classificados como promissores ou sugestivos, mas não houve casos que satisfizessem simultaneamente intervalo de confiança totalmente positivo e $p < 0,05$. Esse resultado mostra que, embora a tendência seja favorável à família generalizada, a evidência estatística é mais fraca nesse cenário.

4.4 Simulações com espaços híbridos clássico-quânticos

Nos experimentos simulados, os ganhos foram geralmente menores do que nos experimentos de hardware. Isso é parcialmente esperado, pois as simulações por vetor de estado só são possíveis para um número limitado de qubits, o que limita a expressividade do PQFM. Além disso, em algumas bases, a linha de base clássica já era muito forte.

Na base Breast Cancer Pathology, conforme a tabela 4.1, o melhor resultado simulado veio do mapa de Heisenberg com seleção SHAP de atributos quânticos. A AUC passou de 0,9847 na linha de base clássica para 0,9911 com atributos quânticos selecionados, e a precisão também aumentou de 0,9574 para 0,9637. A família XYZ gerou melhorias pequenas quando combinada com atributos clássicos, mas seus atributos quânticos isolados foram menos competitivos nessa base.

Algoritmo	Qubits	Atributos	Clássico					PCA Quântico					Clássico+PCA Quântico				
			AUC	F1	Prec.	Revoc.	Acur.	AUC	F1	Prec.	Revoc.	Acur.	AUC	F1	Prec.	Revoc.	Acur.
CD-Ising-glass	13	13	0.8784	0.7797	0.8033	0.7626	0.8034	0.8654	0.7708	0.8014	0.7474	0.7957	0.8754	**0.7894**	**0.8305**	0.7554	**0.8152**
Heisenberg	14	13	0.8784	0.7797	0.8033	0.7626	0.8034	0.8790	0.7690	0.7855	0.7592	0.7911	**0.8855**	**0.7859**	0.7992	**0.7784**	**0.8056**
XYZ-cross/shared-feature	13	13	0.8784	0.7797	0.8033	0.7626	0.8034	0.8387	0.7623	0.7552	0.7771	0.7793	**0.8873**	**0.7933**	0.8026	**0.7900**	**0.8109**
XYZ-cross-only/shared-feature	13	13	0.8784	0.7797	0.8033	0.7626	0.8034	0.8304	0.7368	0.7452	0.7361	0.7601	**0.8821**	0.7791	0.7880	**0.7756**	0.7984
XYZ-diagonal/shared-feature	13	13	0.8784	0.7797	0.8033	0.7626	0.8034	0.8189	0.7216	0.7356	0.7158	0.7482	0.8725	0.7690	0.7873	0.7582	0.7917

Tabela 4.2 – Resultados para a base *Heart Disease* utilizando redução dimensional por PCA sobre os atributos quânticos, com 13 componentes principais, e o protocolo de validação aninhada da Fig. 3.1. Comparam-se as variantes CD-Ising-glass, Heisenberg, XYZ-cross/shared-feature, XYZ-cross-only/shared-feature e XYZ-diagonal/shared-feature. A base clássica utiliza os 13 atributos clínicos originais. O bloco "PCA Quântico" apresenta os resultados obtidos apenas com os componentes principais extraídos dos atributos quânticos, enquanto o bloco "Clássico+PCA Quântico" mostra os resultados obtidos com a união entre os 13 atributos clássicos e os 13 componentes principais quânticos. O PCA foi ajustado sem vazamento de informação dentro do protocolo aninhado. Entradas em negrito indicam, para cada linha e métrica, o melhor resultado quântico ou híbrido quando superior à base clássica.

Na base Cardiac Disease, tabela 4.2, os ganhos foram modestos e dependentes da métrica. Os melhores resultados apareceram em configurações híbridas com PCA aplicado às características quânticas antes da concatenação com as variáveis clássicas. O CD-Ising-glass melhorou a precisão de 0,8033 para 0,8305, enquanto a configuração XYZ cruzada com atributo compartilhado melhorou o recall de 0,7626 para 0,7900.

4.5 Síntese comparativa

A Tabela 4.3 resume os principais achados por regime experimental.

Tabela 4.3 – Síntese qualitativa dos principais resultados.

Experimento	**Principal conclusão**
Molecular Toxicity em QPU	A família Hamiltoniana generalizada apresentou o padrão mais consistente de ganhos pareados, especialmente em `ibm_kingston` e nas configurações multi-eixo.
Breast Cancer Radiology em QPU	A configuração diagonal XYZ melhorou AUC e revocação médias, mas sem evidência pareada consistente para todos os critérios estatísticos.
Breast Cancer Pathology em simulação	O mapa de Heisenberg com seleção SHAP obteve o melhor ganho em AUC, mas a linha de base clássica já era muito forte.
Cardiac Disease em simulação	Ganhos modestos apareceram em espaços híbridos com PCA, sobretudo em precisão e recall.

De forma geral, os resultados apoiam três interpretações. Primeiro, PQFMs Hamiltonianos podem gerar informação complementar aos atributos clássicos em tarefas biomédicas reais. Segundo, a utilidade dessa informação depende fortemente da forma de codificação, dos observáveis e do hardware. Terceiro, a codificação multi-eixo é uma estratégia promissora para aumentar a densidade de informação de circuitos rasos, principalmente quando há restrições no número de qubits disponíveis.

Esses achados não demonstram vantagem quântica no sentido forte. Porém, indicam utilidade quântica de maneira mais heurística. Esse tipo de evidência é relevante para a era NISQ, onde o ruído e o baixo número de qubits é um empecilho para a implementação de algoritmos com vantagem reconhecida em termos de complexidade, como Shor (SHOR, 1997) e Grover (GROVER, 1996), em escala útil.

5 Conclusão

Este trabalho apresentou uma família generalizada de mapas de características quânticas projetadas baseada em Hamiltonianos de dois qubits. A proposta foi motivada pela necessidade de construir representações quânticas flexíveis com possibilidade de codificação de múltiplos atributos por qubit, compatíveis com restrições de hardware e úteis para modelos clássicos de aprendizado supervisionado. Além disso, até onde sabemos a `pqfmlib` é a primeira lib de código aberto de PQFMs, possibilitando testar não somente o nosso modelo aqui apresentado, como também modelos inspirados nas abordagens da Kipu Quantum e do HSBC. Isso garante não somente a reprodutibilidade dos nossos experimentos, como também promove a evolução da área em si.

A formulação proposta amplia os PQFMs mencionados ao permitir campos locais em diferentes eixos de Pauli e interações pares diagonais, cruzadas ou completas. Essa generalização possibilita a codificação resolvida por eixos, na qual diferentes variáveis clássicas podem ser associadas a diferentes direções de Pauli de um mesmo qubit. Com isso, aumenta-se a densidade de informação por qubit sem necessariamente aumentar a profundidade do circuito de forma proibitiva.

Do ponto de vista experimental, os métodos foram avaliados em quatro bases biomédicas públicas. Duas bases foram executadas em processadores quânticos IBM, com até 156 qubits, e duas foram avaliadas em simulação por vetor de estado. A metodologia adotou validação cruzada aninhada, busca de hiperparâmetros separada da avaliação externa, comparação pareada por partições, intervalos de confiança e testes de Wilcoxon. Esse protocolo foi essencial para diferenciar ganhos robustos de tendências exploratórias.

Os resultados indicam que PQFMs Hamiltonianos podem gerar características úteis em problemas reais de classificação biomédica. A família generalizada de dois qubits apresentou o padrão mais consistente de ganhos sobre linhas de base clássicas pareadas, especialmente na base Molecular Toxicity em hardware real. A estratégia multi-eixo se mostrou particularmente interessante nos regimes em que múltiplos atributos precisam ser codificados por qubit. Em Breast Cancer Radiology, os resultados sugeriram ganhos médios, mas com evidência estatística menos forte. Nas bases simuladas, os ganhos foram mais modestos e dependentes da métrica, aparecendo principalmente em espaços híbridos clássico-quânticos.

Apesar dos resultados positivos, algumas limitações devem ser destacadas. Em primeiro lugar, os ganhos observados não constituem uma demonstração de vantagem quântica universal. Eles devem ser entendidos como evidência empírica de utilidade quântica em cenários específicos. Em segundo lugar, o desempenho depende fortemente da

base de dados, do backend, dos observáveis medidos e das estratégias de pós-processamento. Em terceiro lugar, execuções em hardware real estão sujeitas a ruído e exigindo controles cuidadosos de ordenação das amostras e interpretação conservadora dos resultados.

Para trabalhos futuros, destacam-se quatro direções. A primeira é estudar de forma mais sistemática o papel do ruído de hardware, distinguindo efeitos prejudiciais de possíveis regularizações induzidas por ruído. A segunda é explorar mapas de Heisenberg, onde as variáveis são codificadas nos termos de interação, em Hamiltonianos generalizados com conectividades mais ricas, fazendo uso também de estratégias de multi-codificação por eixo. A terceira é investigar dentro da abordagem da família de Hamiltonianos proposta, interações de ordem superior, envolvendo três ou mais qubits, para avaliar se canais adicionais de correlação produzem representações mais úteis. A quarta é desenvolver modelos clássicos que aprendam a fazer a extração de características quânticas, os chamados *classical surrogates* seguindo a linha da Kipu Quantum (FLORES-GARRIGóS et al., 2026), permitindo escalar PQFMs para bases maiores quando a avaliação amostra a amostra em QPU for proibitiva.

Por fim, este trabalho reforça a visão de que, no curto prazo, computadores quânticos podem ser mais úteis como geradores especializados de representações do que como substitutos completos de pipelines clássicas de aprendizado de máquina. A família Hamiltoniana generalizada apresentada aqui contribui para essa direção ao oferecer uma estrutura flexível, implementável em hardware real e empiricamente promissora para a busca de utilidade quântica em aprendizado supervisionado.

Referências

ARUTE, F. et al. Quantum supremacy using a programmable superconducting processor. *Nature*, v. 574, p. 505–510, 2019.

BHARTI, K. et al. Noisy intermediate-scale quantum algorithms. *Reviews of Modern Physics*, v. 94, p. 015004, 2022.

BOIXO, S. et al. Characterizing quantum supremacy in near-term devices. *Nature Physics*, v. 14, p. 595–600, 2018.

CARMO, R. S. *pqfmlib: Projective Quantum Feature Maps Library*. 2026. <https://github.com/rscarmo/pqfmlib>. GitHub repository, accessed June 7, 2026.

CARMO, R. S. do; JUNIOR, E. A.; FANCHINI, F. *Generalized two-qubit Hamiltonian for Projective Quantum Feature Maps*. 2026. Disponível em: <https://arxiv.org/abs/2606.13641>.

CICERI, A. et al. Enhanced fill probability estimates in institutional algorithmic bond trading using statistical learning algorithms with quantum computers. *arXiv preprint arXiv:2509.17715*, 2025.

CLAEYS, P. W. et al. Floquet-engineering counterdiabatic protocols in quantum many-body systems. *Phys. Rev. Lett.*, American Physical Society, v. 123, p. 090602, Aug 2019. Disponível em: <https://link.aps.org/doi/10.1103/PhysRevLett.123.090602>.

D-Wave Quantum Inc. *Fast Anneals and Coherent Quantum Annealing*. [S.l.], 2024. Disponível em: <https://www.dwavequantum.com/media/x3blg5bk/14-1074a-a_fast_anneals_and_coherent_quantum_annealing.pdf>.

FARHI, E.; NEVEN, H. *Classification with quantum neural networks on near term processors*. 2018.

FERENCZI, A. et al. Credit default prediction with projected quantum feature models and ensembles. *arXiv preprint arXiv:2510.01129*, 2025.

FLORES-GARRIGóS, C. et al. *Off-line quantum-advantage feature extraction for industrial production*. 2026.

GLICK, J. R. et al. Covariant quantum kernels for data with group structure. *Nature Physics*, v. 20, p. 479–486, 2024.

GROVER, L. K. A fast quantum mechanical algorithm for database search. In: *Proceedings of the twenty-eighth annual ACM symposium on Theory of computing*. [S.l.: s.n.], 1996. p. 212–219.

HAVLÍČEK, V. et al. Supervised learning with quantum-enhanced feature spaces. *Nature*, v. 567, p. 209–212, 2019.

HUANG, H.-Y. et al. Power of data in quantum machine learning. *Nature Communications*, v. 12, p. 2631, 2021.

HUANG, H.-Y. et al. Power of data in quantum machine learning. *Nature Communications*, v. 12, p. 2631, 2021.

HUERTA-RUIZ, J. R. et al. Quantum coherence and counterdiabatic quantum computing. *New Journal of Physics*, IOP Publishing, v. 27, n. 8, p. 084504, aug 2025. Disponível em: <https://doi.org/10.1088/1367-2630/adf991>.

KLASSEN, J.; TERHAL, B. M. Two-local qubit Hamiltonians: when are they stoquastic? *Quantum*, Verein zur Förderung des Open Access Publizierens in den Quantenwissenschaften, v. 3, p. 139, maio 2019. ISSN 2521-327X. Disponível em: <https://doi.org/10.22331/q-2019-05-06-139>.

LIU, Y.; ARUNACHALAM, S.; TEMME, K. A rigorous and robust quantum speed-up in supervised machine learning. *Nature Physics*, v. 17, p. 1013–1017, 2021.

MCCLEAN, J. R. et al. Barren plateaus in quantum neural network training landscapes. *Nature Communications*, v. 9, n. 1, p. 4812, 2018.

PRESKILL, J. Quantum computing in the NISQ era and beyond. *Quantum*, v. 2, p. 79, 2018.

REBENTROST, P.; MOHSENI, M.; LLOYD, S. Quantum support vector machine for big data classification. *Physical Review Letters*, v. 113, p. 130503, 2014.

SCHULD, M.; KILLORAN, N. Quantum machine learning in feature hilbert spaces. *Physical Review Letters*, v. 122, p. 040504, 2019.

SHOR, P. W. Polynomial-time algorithms for prime factorization and discrete logarithms on a quantum computer. *SIAM Journal on Computing*, v. 26, n. 5, p. 1484–1509, 1997. Disponível em: <https://doi.org/10.1137/S0097539795293172>.

SIMEN, A. et al. Digitized counterdiabatic quantum feature extraction. *arXiv preprint arXiv:2510.13807*, 2025.

SIMEN, A. et al. Quenched quantum feature maps. *arXiv preprint arXiv:2508.20975*, 2025.

WILCOXON, F. Individual comparisons by ranking methods. *Biometrics Bulletin*, [International Biometric Society, Wiley], v. 1, n. 6, p. 80–83, 1945. ISSN 00994987. Disponível em: <http://www.jstor.org/stable/3001968>.

Apêndices

APÊNDICE A – Resumo estatístico complementar

Este apêndice reúne os resultados complementares reportados como gráficos no texto principal da dissertação. A primeira parte apresenta os resultados completos da base *Molecular Toxicity*, que serviram de base para as comparações em hardware quântico discutidas neste trabalho. A segunda parte apresenta a análise estatística pareada dos casos em que as representações quânticas, ou híbridas clássico-quânticas, apresentaram ganhos em relação às respectivas bases clássicas.

Em todas as tabelas, AUC foi utilizada como métrica principal de seleção dos modelos, enquanto F1-score, precisão, recall e acurácia foram consideradas métricas complementares. Os resultados estatísticos pareados seguem os critérios definidos na metodologia: resultados *consistentes* possuem delta médio positivo, intervalo de confiança de 95% inteiramente acima de zero e teste unilateral de Wilcoxon com $p < 0.05$; resultados *promissores* possuem delta médio positivo e $p < 0.05$, mas intervalo de confiança cruzando zero; resultados *sugestivos* possuem delta médio positivo, intervalo cruzando zero e $0.05 \leq p < 0.10$; por fim, *tendências positivas* indicam deltas médios positivos com evidência estatística mais fraca.

A.1 Resultados completos para a base Molecular Toxicity

A base *Molecular Toxicity* foi utilizada como principal experimento em hardware quântico, permitindo comparar diferentes famílias de PQFMs em três regimes de codificação: aproximadamente 52, 78 e 156 qubits. Os experimentos foram executados nos processadores `ibm_fez`, `ibm_kingston` e `ibm_marrakesh`. As Tabelas A.1, A.2 e A.3 apresentam, respectivamente, os resultados para o CD-Ising-glass, o mapa de Heisenberg e a família Hamiltoniana generalizada.

QPU	Qubits	Clássico					Quântico 1-local					Quântico 2-local				
		AUC	**F1**	**Prec.**	**Rev.**	**Acur.**	**AUC**	**F1**	**Prec.**	**Rev.**	**Acur.**	**AUC**	**F1**	**Prec.**	**Rev.**	**Acur.**
–	–	0.5653	0.7135	0.6878	0.7461	0.6011	–	–	–	–	–	–	–	–	–	–
ibm_fez	52	–	–	–	–	–	0.5579	**0.7234**	**0.6899**	**0.7678**	**0.6114**	0.4907	0.7044	0.6740	0.7496	0.5836
ibm_kingston	52	–	–	–	–	–	0.5242	0.7122	0.6818	0.7513	0.5948	**0.6052**	**0.7314**	**0.7066**	**0.7670**	**0.6275**
ibm_marrakesh	52	–	–	–	–	–	**0.5693**	**0.7195**	0.6871	**0.7600**	**0.6047**	0.5480	0.7156	0.6877	0.7548	0.6043
ibm_fez	78	–	–	–	–	–	0.5206	0.7008	0.6727	0.7391	0.5823	0.4956	0.6977	0.6704	0.7383	0.5795
ibm_kingston	78	–	–	–	–	–	0.5371	**0.7183**	**0.6884**	**0.7557**	**0.6035**	0.5081	0.6955	0.6730	0.7304	0.5789
ibm_marrakesh	78	–	–	–	–	–	0.5635	0.7054	0.6734	0.7470	0.5866	0.5177	**0.7198**	0.6786	**0.7748**	**0.6029**
ibm_fez	156	–	–	–	–	–	**0.6040**	**0.7315**	**0.6992**	**0.7730**	**0.6241**	0.5857	0.7287	0.6956	**0.7730**	0.6189
ibm_kingston	156	–	–	–	–	–	**0.6220**	0.7358	**0.7092**	0.7739	0.6329	0.6144	**0.7480**	0.7088	**0.7991**	**0.6437**
ibm_marrakesh	156	–	–	–	–	–	**0.5956**	**0.7266**	**0.6946**	0.7670	**0.6153**	0.5333	0.7191	0.6792	**0.7713**	0.6001

Tabela A.1 – Resumo de desempenho do mapa CD-Ising-glass na base *Molecular Toxicity*, utilizando o protocolo de validação aninhada. Os resultados são apresentados para três processadores IBM e para regimes de codificação com 52, 78 e 156 qubits. As características quânticas foram extraídas a partir de observáveis 1-locais (Z) e 2-locais (ZZ). Entradas em negrito indicam, para cada linha e métrica, o melhor resultado quântico quando superior à base clássica correspondente.

QPU	Qubits	Atributos	Clássico					Heisenberg melhor 1-local				
			AUC	**F1**	**Prec.**	**Rev.**	**Acur.**	**AUC**	**F1**	**Prec.**	**Rev.**	**Acur.**
ibm_fez	53	156	0.5653	0.7135	0.6878	0.7461	0.6011	0.5444	**0.7159**	0.6838	**0.7574**	**0.6036**
ibm_kingston	53	156	0.5653	0.7135	0.6878	0.7461	0.6011	0.5410	0.7025	0.6855	0.7287	0.5913
ibm_marrakesh	53	156	0.5653	0.7135	0.6878	0.7461	0.6011	0.5233	0.7021	0.6743	0.7383	0.5855
ibm_fez	79	156	0.5653	0.7135	0.6878	0.7461	0.6011	0.5241	0.7062	0.6668	**0.7565**	0.5831
ibm_kingston	79	156	0.5653	0.7135	0.6878	0.7461	0.6011	**0.5777**	0.7110	**0.6951**	0.7348	**0.6036**
ibm_marrakesh	79	156	0.5653	0.7135	0.6878	0.7461	0.6011	**0.5742**	**0.7230**	**0.6966**	**0.7626**	**0.6134**
ibm_fez	156	155	0.5634	0.7049	0.6836	0.7330	0.5918	**0.5880**	**0.7215**	**0.6906**	**0.7609**	**0.6112**
ibm_kingston	156	155	0.5634	0.7049	0.6836	0.7330	0.5918	**0.5685**	**0.7113**	**0.6875**	**0.7452**	**0.6011**
ibm_marrakesh	156	155	0.5634	0.7049	0.6836	0.7330	0.5918	**0.5890**	**0.7319**	**0.6958**	**0.7791**	**0.6221**

Tabela A.2 – Resultados do mapa de Heisenberg na base *Molecular Toxicity*, utilizando validação aninhada. Para cada QPU e orçamento de qubits, apresenta-se a base clássica e a melhor configuração 1-local do mapa de Heisenberg, selecionada pela maior AUC entre os observáveis X, Y e Z. Todas as métricas quânticas de uma mesma linha correspondem ao mesmo observável selecionado. Entradas em negrito indicam resultados do mapa de Heisenberg que superam a base clássica correspondente.

QPU	Qubits	Configuração	Atrib.	Clássico					Quântico 1-local					Quântico 2-local				
				AUC	F1	Prec.	Rev.	Acur.	AUC	F1	Prec.	Rev.	Acur.	AUC	F1	Prec.	Rev.	Acur.
ibm_kingston	52	cross-only, multi-axis	156	0.5653	0.7135	0.6878	0.7461	0.6011	**0.6096**	**0.7492**	**0.7086**	**0.8000**	**0.6451**	0.5739	0.7356	0.6956	0.7878	0.6234
ibm_kingston	52	diagonal, multi-axis	156	0.5653	0.7135	0.6878	0.7461	0.6011	0.5536	0.7177	0.6997	0.7470	0.6148	**0.5713**	**0.7487**	**0.7113**	**0.7965**	**0.6455**
ibm_kingston	78	cross-only, multi-axis	156	0.5653	0.7135	0.6878	0.7461	0.6011	**0.6049**	**0.7470**	**0.7129**	**0.7930**	**0.6456**	0.5225	0.7099	0.6784	0.7539	0.5929
ibm_kingston	78	diagonal, multi-axis	156	0.5653	0.7135	0.6878	0.7461	0.6011	**0.6088**	**0.7385**	**0.7105**	0.7774	**0.6359**	0.5620	0.7321	0.6933	**0.7843**	0.6225
ibm_kingston	156	full/shared-feature	156	0.5653	0.7135	0.6878	0.7461	0.6011	**0.6222**	**0.7520**	**0.7079**	**0.8096**	**0.6472**	0.5436	0.7067	0.6826	0.7435	0.5942

Tabela A.3 – Resultados da família XYZ de mapas de características na base *Molecular Toxicity*, no processador `ibm_kingston`, utilizando validação aninhada. A tabela compara variantes com termos cruzados, diagonais e completos/shared-feature em diferentes orçamentos de qubits. Para as características 1-locais e 2-locais, as configurações são selecionadas pela maior AUC entre os observáveis disponíveis. Entradas em negrito indicam, para cada linha e métrica, o melhor resultado quântico quando superior à base clássica correspondente.

A.2 Análise estatística pareada

Nesta seção são apresentados os resultados da análise pareada dos casos em que as representações quânticas ou híbridas apresentaram algum ganho em relação à base clássica. Para cada caso, reporta-se o delta médio pareado, o intervalo de confiança de 95% para esse delta e o valor de p do teste unilateral de Wilcoxon, com hipótese alternativa de que a configuração avaliada supera a base clássica. As tabelas seguem o formato do Apêndice B do artigo original.

A.2.1 ISPY1

Algoritmo	Qubits	Seleção	Métrica	Δ médio	IC95% Δ	Wilcoxon greater p	Status
Nenhum bloco de características selecionado atingiu o critério de resultado consistente.							
XY-cross-only	156	$\langle YY \rangle$	F1	+0.0260	[-0.0022, +0.0542]	0.0422	Promissor
XY-cross-only	156	$\langle YY \rangle$	Precisão	+0.0129	[-0.0086, +0.0344]	0.0889	Sugestivo
XY-cross-only	156	$\langle YY \rangle$	Acurácia	+0.0192	[-0.0056, +0.0440]	0.0512	Sugestivo
XYZ-full	124	$\langle XX \rangle$	AUC	+0.0205	[-0.0116, +0.0526]	0.0705	Sugestivo
XYZ-diagonal	124	$\langle Z \rangle$	AUC	+0.0307	[-0.0061, +0.0675]	0.0563	Sugestivo

Tabela A.4 – Resumo estatístico pareado para a base *ISPY1*, considerando apenas os melhores blocos de características quânticas selecionados pela AUC. Nenhuma configuração atingiu o critério de resultado consistente; os ganhos encontrados foram classificados como promissores ou sugestivos.

A.2.2 Breast Cancer Pathology

Algoritmo	**Qubits**	**Seleção**	**Métrica**	**Δ médio**	**IC95% Δ**	**Wilcoxon greater p**	**Status**
Heisenberg	19/20	SHAP Quantum	AUC	+0.0064	[+0.0008, +0.0121]	0.0028	Consistente
Heisenberg	19/20	SHAP Quantum	Precisão	+0.0062	[+0.0004, +0.0121]	0.0173	Consistente
Heisenberg	19/20	SHAP Quantum	F1	+0.0041	[-0.0002, +0.0084]	0.0469	Promissor
Heisenberg	19/20	SHAP Quantum	Acurácia	+0.0053	[-0.0002, +0.0108]	0.0214	Promissor
Heisenberg	19/20	SHAP Classical+Quantum	Precisão	+0.0046	[-0.0002, +0.0094]	0.0324	Promissor
Heisenberg	19/20	SHAP Classical+Quantum	Acurácia	+0.0037	[-0.0015, +0.0089]	0.0653	Sugestivo
XYZ-cross/shared-feature	20	SHAP Classical+Quantum	Revocação	+0.0028	[-0.0017, +0.0073]	0.0729	Sugestivo
CD-Ising-glass	20	SHAP Classical+Quantum	Precisão	+0.0022	[-0.0020, +0.0064]	0.0985	Sugestivo

Tabela A.5 – Melhorias estatisticamente sustentadas, promissoras e sugestivas em relação à base clássica para a base *Breast Cancer Pathology*. Os resultados consideram seleção de atributos por SHAP em características quânticas e em espaços híbridos clássico-quânticos.

A.2.3 Cardiac Disease

Algoritmo	**Qubits**	**Seleção**	**Métrica**	**Δ médio**	**IC95% Δ**	**Wilcoxon greater p**	**Status**
CD-Ising-glass	13	Classical+PCA Quantum	Precisão	+0.0272	[+0.0061, +0.0484]	0.001776	Consistente
XYZ-cross/shared-feature	13	Classical+PCA Quantum	Revocação	+0.0273	[+0.0075, +0.0471]	0.005875	Consistente
CD-Ising-glass	13	Classical+PCA Quantum	Acurácia	+0.0119	[-0.0034, +0.0272]	0.02579	Promissor
CD-Ising-glass	13	Classical+PCA Quantum	F1	+0.0096	[-0.0078, +0.0271]	0.08863	Sugestivo
Heisenberg	13	Classical+PCA Quantum	Revocação	+0.0158	[-0.0012, +0.0327]	0.05582	Sugestivo
XYZ-cross/shared-feature	13	PCA Quantum	Revocação	+0.0144	[-0.0081, +0.0369]	0.08833	Sugestivo
XYZ-cross/shared-feature	13	Classical+PCA Quantum	F1	+0.0136	[-0.0031, +0.0302]	0.09290	Sugestivo
Heisenberg	13	Classical+PCA Quantum	AUC	+0.0071	[-0.0082, +0.0224]	0.3497	Tendência positiva
Heisenberg	13	Classical+PCA Quantum	F1	+0.0062	[-0.0083, +0.0207]	0.2947	Tendência positiva
XYZ-cross/shared-feature	13	Classical+PCA Quantum	AUC	+0.0090	[-0.0045, +0.0225]	0.2573	Tendência positiva
XYZ-cross/shared-feature	13	Classical+PCA Quantum	Acurácia	+0.0076	[-0.0073, +0.0224]	0.1908	Tendência positiva
XYZ-cross-only/shared-feature	13	Classical+PCA Quantum	Revocação	+0.0129	[-0.0055, +0.0314]	0.1214	Tendência positiva

Tabela A.6 – Resumo estatístico pareado para a base *Cardiac Disease*, utilizando PCA sobre atributos quânticos com 13 componentes principais. Os casos são agrupados segundo os critérios de interpretação estatística definidos na metodologia: consistente, promissor, sugestivo e tendência positiva.